Липецкий государственный технический университет

Институт компьютерных наук
Кафедра прикладной математики и системного анализа

Отчет по лабораторной работе № 1
по дисциплине «Интеллектуальные методы анализа данных»
на тему «Разведочный анализ данных (EDA) и визуализация»

Студент _____ Комаров М.А.
подпись, дата фамилия, инициалы

Группа ПМ-24-2

Руководитель
к.т.н., доцент _____ Сысоев А.С.
учёная степень, учёное звание подпись, дата фамилия, инициалы

Липецк 2026 г.

Задание кафедры

Освоить полный цикл разведочного анализа данных (EDA): проверку базовых предположений измерительного процесса, расчёт описательных статистик, построение и интерпретацию графиков (гистограмм, Box Plot, CDF, диаграмм рассеяния), выявление выбросов, аномалий и взаимосвязей, а также формулирование гипотез для дальнейшего моделирования.

1. Изучить философию и цели разведочного анализа данных.
2. Освоить проверку четырёх фундаментальных предположений измерительного процесса с помощью 4-Plot.
3. Изучить меры центральной тенденции и меры разброса.
4. Освоить построение и интерпретацию гистограмм, Box Plot, CDF и KDE.
5. Изучить методы анализа взаимосвязей: диаграммы рассеяния и корреляции.
6. Провести сравнительный анализ распределений по группам.
7. Сформулировать гипотезы для дальнейшего моделирования.

Оглавление

Задание кафедры 1
Введение 4
1. Выполнение лабораторной работы 7
Часть 1. Подготовка и первичный осмотр данных 7
Часть 2. Проверка базовых предположений (4-Plot) 13
Часть 3. Описательная статистика 19
Часть 4. Визуализация распределений 22
Часть 5. Анализ взаимосвязей 31
Часть 6. Сравнительный анализ 36
Выводы и практические рекомендации 40

Введение

Разведочный анализ данных (Exploratory Data Analysis, EDA) представляет собой совокупность методов, предназначенных для первичного изучения данных. Он позволяет получить представление о структуре исследуемого набора данных, оценить основные статистические характеристики, выявить выбросы и аномалии, а также обнаружить взаимосвязи между переменными.

Проведение разведочного анализа является важным этапом статистического исследования, поскольку результаты такого анализа помогают выбрать подходящие методы дальнейшего моделирования и сформулировать проверяемые статистические гипотезы.

Описание выбранного датасета

В работе используется датасет *Wine Quality*, загруженный из файла `wine_quality_merged.csv`. Датасет объединяет два исходных набора данных — *Red Wine Quality* и *White Wine Quality* — и содержит информацию о физико-химических свойствах красных и белых вин, а также экспертные оценки их качества.

- **Название датасета:** Wine Quality (Red and White Wine Quality).
- **Описание:** Датасет содержит измерения физико-химических характеристик образцов вина. Для каждого наблюдения указаны показатели кислотности, содержание сахара, хлоридов, диоксида серы, плотность, pH, содержание сульфатов и алкоголя, а также экспертная оценка качества вина и его тип (красное или белое).
- **Количество наблюдений:** 6497.
- **Количество признаков:** 13.
- **Тип признаков:** одиннадцать количественных непрерывных признака:
  - `fixed acidity (фиксированная кислотность)`;
  - `volatile acidity (летучая кислотность)`;
  - `citric acid (лимонная кислота)`;
  - `residual sugar (остаточный сахар)`
  - `chlorides (хлориды)`;
  - `free sulfur dioxide (свободный диоксид серы)`;
  - `total sulfur dioxide (общий диоксид серы)`;

– density (плотность);
– pH (кислотность);
– sulphates (сульфаты);
– alcohol (содержание алкоголя).

Один порядковый категориальный признак — quality (оценка качества). Один номинальный категориальный признак — type (тип вина: red или white).

— **Шкалы измерений:** количественные признаки измерены по шкале отношений, признак quality — по порядковой шкале, признак type — по номинальной шкале. Интервальная шкала в датасете не представлена.
— **Наличие пропусков:** пропущенные значения отсутствуют. Общее количество пропусков равно нулю. При этом в датасете обнаружено 1169 дублирующихся наблюдений.

Методика исследования

Исследование проводилось в несколько этапов с использованием языка программирования Python и библиотек pandas, numpy, matplotlib, seaborn и scipy.

1. На первом этапе был загружен датасет Wine Quality из файла wine_quality_merged.csv. Были определены размер датасета, количество наблюдений и признаков, а также типы данных отдельных переменных..
2. На втором этапе была выполнена первичная проверка качества данных. Для каждого признака проверялось наличие пропущенных значений и дубликатов.
3. На третьем этапе для количественных признаков были рассчитаны основные описательные статистики: среднее арифметическое, медиана, мода, стандартное отклонение, асимметрия и эксцесс. Сравнение среднего значения и медианы использовалось для предварительной оценки асимметрии распределений и анализа корректности вычисления среднего.
4. На четвёртом этапе были построены графики для проверки фундаментальных предположений измерительного процесса. Использовались

графики последовательности наблюдений, лаговые диаграммы, гистограммы и Q–Q-графики.

5. График последовательности наблюдений использовался для выявления изменений среднего уровня и возможной упорядоченности данных. Лаговая диаграмма применялась для оценки зависимости между соседними наблюдениями.
6. Гистограммы использовались для анализа формы распределений, выявления асимметрии и наличия нескольких групп значений. Q–Q-графики применялись для предварительной оценки соответствия распределений нормальному закону.
7. На пятом этапе были исследованы распределения количественных признаков с помощью гистограмм с различным числом бинов, Box Plot, эмпирических функций распределения (CDF) и ядерной оценки плотности (KDE). Выполнена проверка потенциальных выбросов по правилу $1{,}5 \cdot \mathrm{IQR}$.
8. На шестом этапе был проведён анализ взаимосвязей между признаками. Использовались диаграммы рассеяния с линиями линейной регрессии, ковариационная матрица, матрица коэффициентов корреляции Пирсона и матрица диаграмм рассеяния. Дополнительно проверялось влияние потенциальных выбросов на корреляционные связи.
9. На седьмом этапе был выполнен сравнительный анализ распределений количественных признаков по группам, заданным категориальной переменной type. Сравнение проводилось с помощью Box Plot по группам, эмпирических функций распределения и численного сопоставления медиан и разброса.
10. На заключительном этапе результаты визуального и статистического анализа были сопоставлены между собой. На основании полученных результатов были сформулированы статистические выводы и гипотезы для дальнейшего моделирования.

1. Выполнение лабораторной работы

Часть 1. Подготовка и первичный осмотр данных

На первом этапе была выполнена загрузка датасета Wine Quality, проведён его первичный осмотр, определены размерность и типы данных, проверено наличие пропущенных значений и дубликатов. Кроме того, для каждого признака были определены тип и шкала измерений, а также проверена корректность вычисления среднего значения.

Загрузка данных и первичный осмотр

Для работы с данными были подключены библиотеки `pandas`, `numpy`, `matplotlib`, `seaborn` и `scipy`. Датасет был загружен из файла `wine_quality_merged.csv`.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy import stats
from IPython.display import display

# Загрузка данных
df = pd.read_csv('wine_quality_merged.csv')

# Первичный осмотр
print("Размерность:", df.shape)
print("Количество строк:", df.shape[0], "| Количество столбцов:",
↪  df.shape[1])
print()
print("Типы данных:")
print(df.dtypes)
print()
print('Первые пять строк:')
display(df.head())
print('Последние пять строк:')
display(df.tail())
```

В результате выполнения кода было установлено, что размерность датасета составляет $(6497, 13)$. Это означает, что набор данных содержит 6497 наблюдений и 13 признаков.

Первые пять строк датасета представлены в таблице 1, а последние пять строк — в таблице 2.

Таблица 1. Первые пять строк датасета `Wine Quality`

id	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality	type
0	7,4	0,70	0,00	1,9	0,076	11,0	34,0	0,9978	3,51	0,56	9,4	5	*red*
1	7,8	0,88	0,00	2,6	0,098	25,0	67,0	0,9968	3,20	0,68	9,8	5	*red*
2	7,8	0,76	0,04	2,3	0,092	15,0	54,0	0,9970	3,26	0,65	9,8	5	*red*
3	11,2	0,28	0,56	1,9	0,075	17,0	60,0	0,9980	3,16	0,58	9,8	6	*red*
4	7,4	0,70	0,00	1,9	0,076	11,0	34,0	0,9978	3,51	0,56	9,4	5	*red*

Таблица 2. Последние пять строк датасета `Wine Quality`

id	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality	type
6492	6,2	0,21	0,29	1,6	0,039	24,0	92,0	0,99114	3,27	0,50	11,2	6	*white*
6493	6,6	0,32	0,36	8,0	0,047	57,0	168,0	0,99490	3,15	0,46	9,6	5	*white*
6494	6,5	0,24	0,19	1,2	0,041	30,0	111,0	0,99254	2,99	0,46	9,4	6	*white*
6495	5,5	0,29	0,30	1,1	0,022	20,0	110,0	0,98869	3,34	0,38	12,8	7	*white*
6496	6,0	0,21	0,38	0,8	0,020	22,0	98,0	0,98941	3,26	0,32	11,8	6	*white*

Проверка пропущенных значений и дубликатов

Для проверки качества данных был использован следующий код:

```
print("Пропуски по столбцам:")
print(df.isnull().sum())
print()

print("Всего пропусков:", df.isnull().sum().sum())
print()

print("Количество дубликатов:", df.duplicated().sum())
print()

print("Дубликаты:")
display(df[df.duplicated()])
```

В результате проверки было установлено, что пропущенные значения отсутствуют во всех столбцах датасета. Общее количество пропусков равно нулю. При этом было обнаружено одно дублирующееся наблюдение.

Таблица 3. Результаты проверки пропусков и дубликатов

Показатель	Значение
Общее количество пропусков	0
Количество дубликатов	1177

В результате проверки было установлено, что пропущенные значения отсутствуют во всех столбцах датасета. Общее количество пропусков равно нулю. При этом было обнаружено 1177 дублирующихся наблюдений. На данном этапе дубликаты были зафиксированы, но не удалялись, поскольку целью работы является первичный разведочный анализ исходного датасета.

Определение типов признаков

Для определения типов данных и количества уникальных значений в каждом столбце использовался следующий код:

```
for col in df.columns:
        print(f"{col}: тип = {df[col].dtype}, "
                f"уникальных значений = {df[col].nunique()}")

print()
print("Классы в 'type':")
print(df['type'].value_counts())
```

Результаты выполнения кода представлены в таблицах 4 и 5.

Таблица 4. Типы и количество уникальных значений признаков

Признак	Тип данных	Количество уникальных значений
fixed acidity	float64	106
volatile acidity	float64	187
citric acid	float64	89
residual sugar	float64	316
chlorides	float64	214
free sulfur dioxide	float64	135
total sulfur dioxide	float64	276
density	float64	998
pH	float64	108
sulphates	float64	111
alcohol	float64	111
quality	int64	7
type	str	2

Таблица 5. Распределение наблюдений по типам вина

Классы в 'type':	Количество наблюдений
white	4898
red	1599

Таким образом, датасет содержит 11 количественных признаков и 2 категориальных признака (type и quality). Признак quality является порядковой переменной, так как оценки качества имеют естественный порядок. Признак type — номинальный. Наблюдения распределены между двумя типами вина: красное и белое.

Типы и шкалы измерений признаков

Количественные признаки (например, fixed acidity, volatile acidity, alcohol) представляют собой измерения физико-химических свойств и относятся к шкале отношений. Признак quality является категориальным порядковым признаком. Признак type является категориальным номинальным признаком.

Таблица 6. Типы и шкалы измерений признаков

Признак	Тип признака	Шкала измерений
fixed acidity	количественный непрерывный	отношений
volatile acidity	количественный непрерывный	отношений
citric acid	количественный непрерывный	отношений
residual sugar	количественный непрерывный	отношений
chlorides	количественный непрерывный	отношений
free sulfur dioxide	количественный непрерывный	отношений
total sulfur dioxide	количественный непрерывный	отношений
density	количественный непрерывный	отношений
pH	количественный непрерывный	отношений
sulphates	количественный непрерывный	отношений
alcohol	количественный непрерывный	отношений
quality	количественный дискретный	порядковая
type	категориальный номинальный	номинальная

Проверка корректности вычисления среднего

Для проверки центральной тенденции использовалась переменная `features`, содержащая названия количественных признаков:

```
# Анализ корректности вычисления среднего для каждого признака
analysis = pd.DataFrame({
        'Среднее': df[features].mean(),
        'Медиана': df[features].median(),
        'Мода': df[features].mode().iloc[0],
        'Ст. откл.': df[features].std(ddof=1),
        'Асимметрия': df[features].skew(),
        'Эксцесс': df[features].kurt(),
})

# абсолютное и относительное расхождение среднего и медианы
analysis['|Среднее − Медиана|'] = (analysis['Среднее'] -
↪  analysis['Медиана']).abs()
analysis['Расхождение, %'] = (
analysis['|Среднее − Медиана|'] / analysis['Медиана'].abs() * 100
)

# коэффициент вариации
analysis['CV, %'] = analysis['Ст. откл.'] / analysis['Среднее'] * 100

# оценка корректности среднего
def judge(row):
if row['Расхождение, %'] < 5 and abs(row['Асимметрия']) < 0.5:
return 'Среднее корректно (симметричное распределение)'
elif row['Расхождение, %'] < 15 and abs(row['Асимметрия']) < 1:
return 'Среднее приемлемо, есть умеренная асимметрия'
```

```
else:
return 'Среднее смещено (асимметрия / влияние выбросов)'

analysis['Вывод'] = analysis.apply(judge, axis=1)

display(analysis.round(3))
```

Среднее арифметическое характеризует общий уровень значений признака. Медиана делит упорядоченный ряд наблюдений на две равные части, а мода показывает наиболее часто встречающееся значение.

Таблица 7. Средние значения количественных признаков

Признак	Среднее значение	Медиана	Мода
fixed acidity	7,215	7,000	6,800
volatile acidity	0,340	0,290	0,280
citric acid	0,319	0,310	0,300
residual sugar	5,443	3,000	2,000
chlorides	0,056	0,047	0,044
free sulfur dioxide	30,525	29,000	29,000
total sulfur dioxide	115,745	118,000	111,000
desity	0,995	0,995	0,997
pH	3,219	3,210	3,160
sulphates	0,531	0,510	0,500
alcohol	10,492	10,300	9,500

Вывод по части 1

В результате первичного осмотра было установлено, что датасет Wine Quality содержит 6497 наблюдений и 13 признаков. Одиннадцать признаков являются количественными непрерывными признаками, измеренными по

шкале отношений, признак `quality` — количественный дискретный, а признак `type` является номинальным категориальным признаком.

Пропущенные значения в датасете отсутствуют, однако обнаружено 1177 дублирующихся наблюдений. Вычисление среднего значения корректно только для количественных признаков. Полученные данные пригодны для дальнейшего разведочного анализа и построения статистических визуализаций.

Часть 2. Проверка базовых предположений (4-Plot)

В данной части была выполнена проверка четырёх фундаментальных предположений измерительного процесса с помощью графиков последовательности наблюдений, лаговых диаграмм, гистограмм и Q–Q-графиков.

Run Sequence Plot

Run Sequence Plot используется для анализа изменения значений признака в порядке следования наблюдений, а также для проверки постоянства среднего уровня и вариации.

```
fig, axes = plt.subplots(4, 3, figsize=(15, 14))
axes = axes.flatten()
for i, col in enumerate(features):
        ax = axes[i]
        ax.plot(df[col], marker='.', markersize=3, linewidth=0.8)
        ax.set_title(f'Run Sequence Plot: {col}')
        ax.set_xlabel('Индекс наблюдения')
        ax.set_ylabel('Значение')
plt.tight_layout()
plt.show()
```

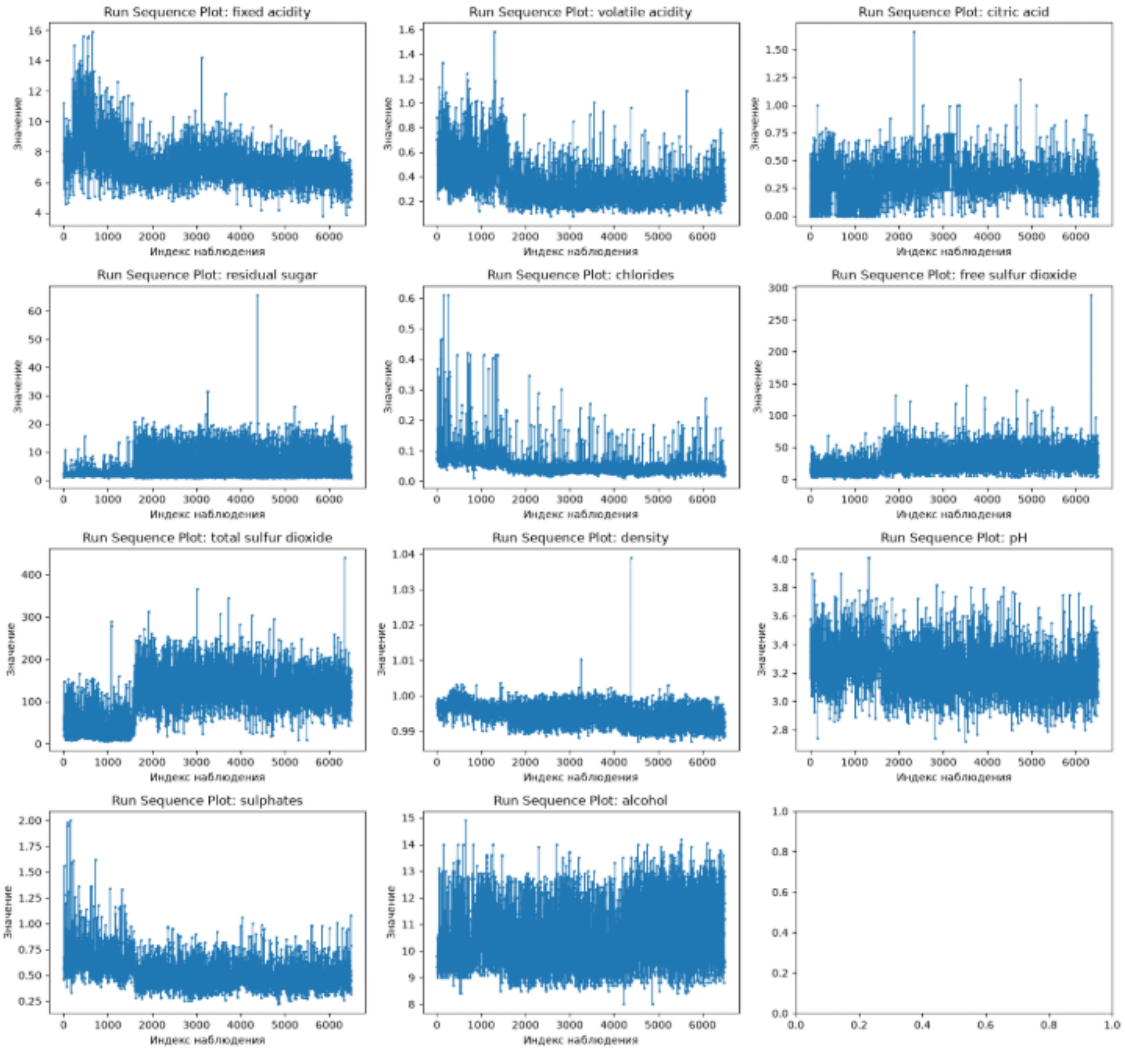


Рисунок 1 – Графики последовательности наблюдений

На графиках последовательности наблюдений видны изменения среднего уровня. Это связано с тем, что в датасете сначала идут наблюдения для одного типа вина, а затем для другого. Следовательно, общий средний уровень признаков не является постоянным для всей выборки. Предположение о фиксированном положении нарушается.

Lag Plot

Lag Plot используется для анализа зависимости между соседними наблюдениями. В данном случае сравниваются значения признака в текущем наблюдении $x[t]$ и следующем наблюдении $x[t+1]$.

```
fig, axes = plt.subplots(4, 3, figsize=(15, 14))
axes = axes.flatten()
```

```
for i, col in enumerate(features):
        ax = axes[i]
        ax.scatter(df[col][:-1], df[col][1:], s=10, alpha=0.6)
        ax.set_title(f'Lag Plot: {col}')
        ax.set_xlabel('x[t]')
        ax.set_ylabel('x[t+1]')
        ax.set_aspect('equal')
plt.tight_layout()
plt.show()
```

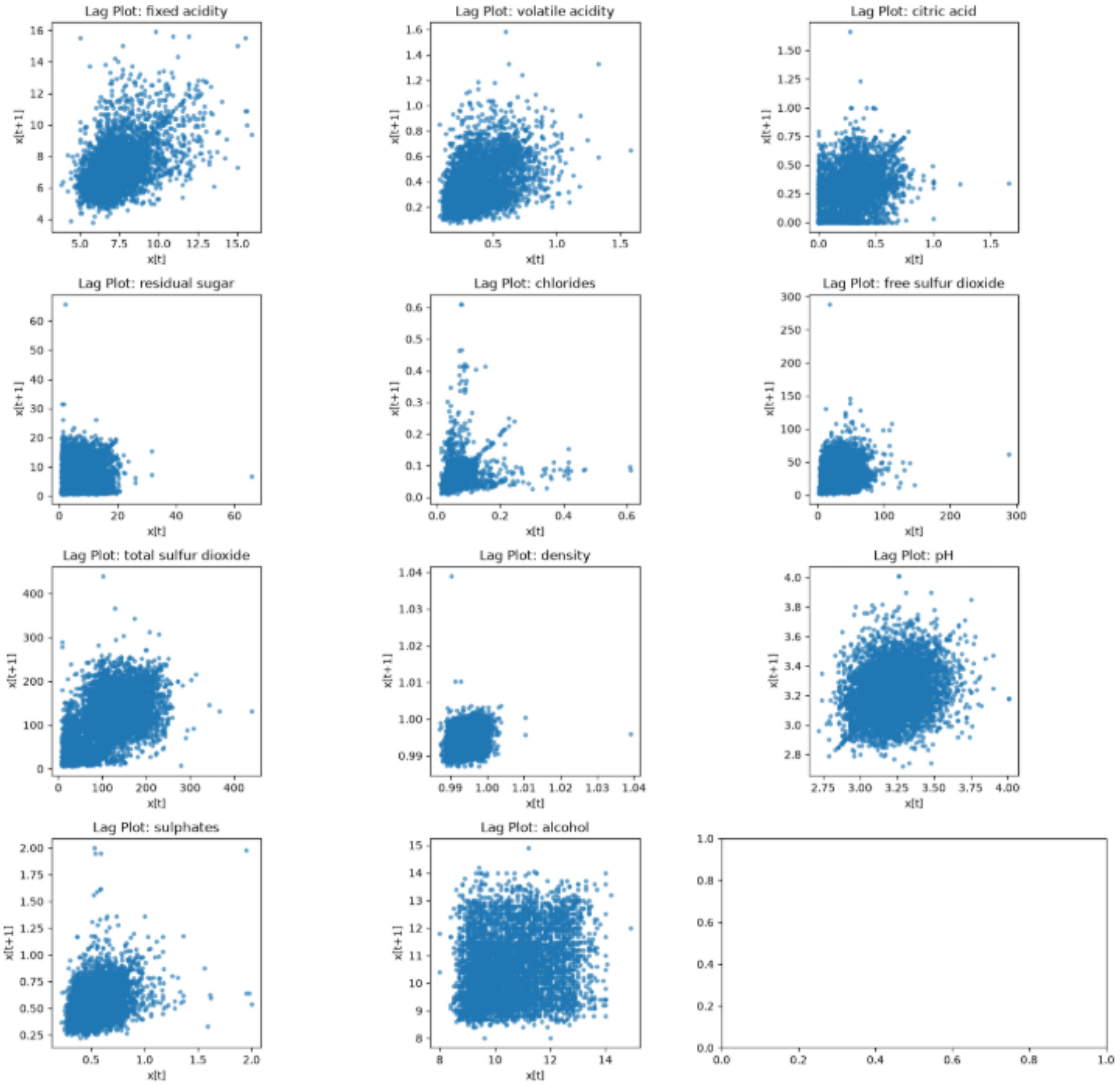


Рисунок 2 – Лаговые диаграммы количественных признаков

На Lag Plot наблюдается определённая структура точек. Соседние значения часто похожи друг на друга. Однако такая зависимость не является временной автокорреляцией, поскольку данные не представляют собой времен-

ной ряд. Структура возникает из-за порядка строк в датасете: наблюдения одного типа вина расположены последовательно.

Гистограммы

Гистограммы используются для анализа формы распределения признаков, выявления асимметрии, нескольких пиков и отдельных областей концентрации значений.

```
fig, axes = plt.subplots(4, 3, figsize=(15, 14))
axes = axes.flatten()
for i, col in enumerate(features):
        ax = axes[i]
        ax.hist(df[col], bins=20, edgecolor='black', alpha=0.8)
        ax.set_title(f'Гистограмма: {col}')
        ax.set_xlabel(col)
        ax.set_ylabel('Частота')
plt.tight_layout()
plt.show()
```

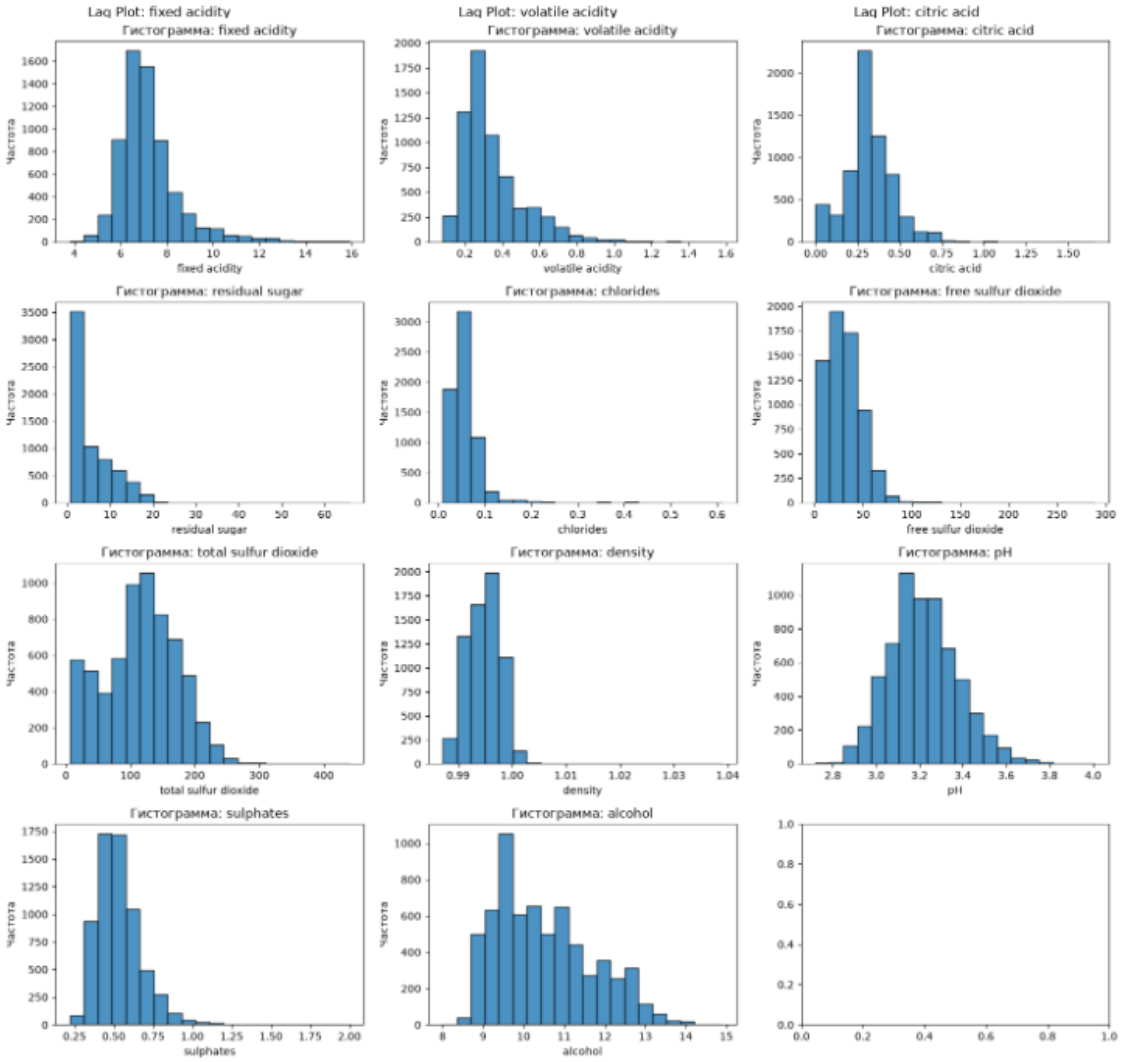


Рисунок 3 – Гистограммы количественных признаков

Гистограммы показывают, что распределения большинства признаков являются асимметричными и имеют несколько локальных пиков. Это связано с тем, что в общей выборке объединены два типа вина, имеющие различные физико-химические свойства. Следовательно, для общей выборки предположение о фиксированном распределении нарушается.

Normal Probability Plot

Normal Probability Plot, или Q–Q-график, используется для проверки соответствия распределения признака нормальному закону.

```
fig, axes = plt.subplots(4, 3, figsize=(15, 14))
axes = axes.flatten()
for i, col in enumerate(features):
        ax = axes[i]
```

```
        stats.probplot(df[col], dist='norm', plot=ax)
        ax.set_title(f'Q-Q Plot: {col}')
plt.tight_layout()
plt.show()
```

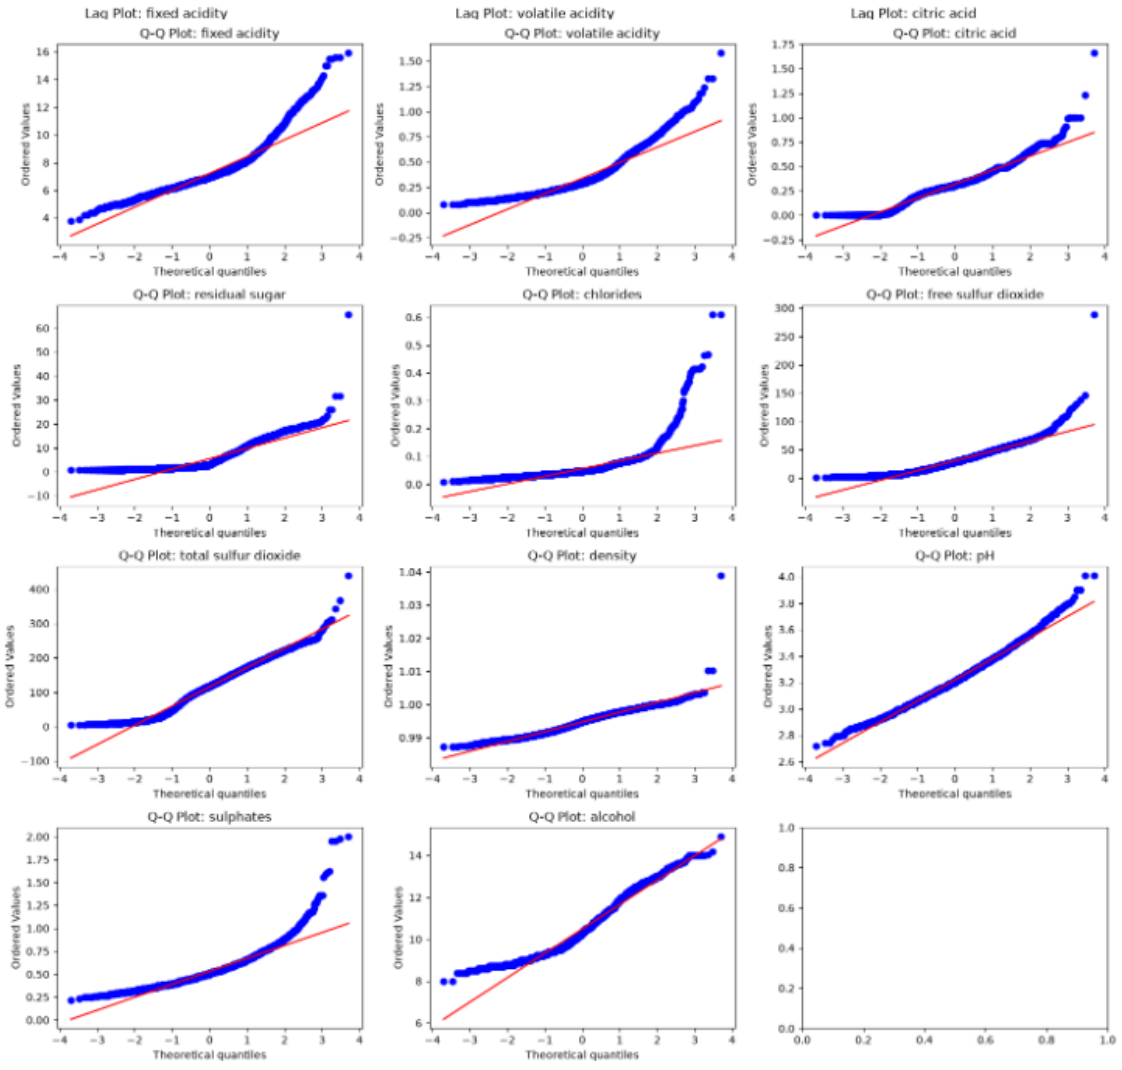


Рисунок 4 – Normal Probability Plot количественных признаков

Для большинства признаков точки значительно отклоняются от прямой. Это связано с наличием двух групп наблюдений, соответствующих разным типам вина. Следовательно, общее распределение этих признаков нельзя считать нормальным.

Вывод по части 2

В результате проверки базовых предположений было установлено, что наблюдения датасета `Wine Quality` расположены неслучайно. Это связано

с тем, что объекты одного типа вина идут последовательно. Гистограммы и `Normal Probability Plot` показывают, что объединённые распределения признаков не являются нормальными. Это объясняется смешением двух различных групп объектов. Поэтому предположения о случайности, постоянстве среднего уровня, фиксированной вариации и нормальности общей выборки не выполняются полностью

Часть 3. Описательная статистика

На данном этапе для количественных признаков датасета Wine Quality были рассчитаны меры центральной тенденции и меры разброса. Анализ проводился для 11 признаков.

Меры центральной тенденции

Для описания центрального положения распределений были рассчитаны среднее арифметическое, медиана и мода.

```
mean_values = df[features].mean()
median_values = df[features].median()
mode_values = df[features].mode().iloc[0]

central_tendency = pd.DataFrame({
        'Среднее': mean_values,
        'Медиана': median_values,
        'Мода': mode_values
})
display(central_tendency.round(3))
```

Таблица 8. Средние значения количественных признаков

Признак	Среднее значение	Медиана	Мода
fixed acidity	7,215	7,000	6,800
volatile acidity	0,340	0,290	0,280
citric acid	0,319	0,310	0,300
residual sugar	5,443	3,000	2,000
chlorides	0,056	0,047	0,044
free sulfur dioxide	30,525	29,000	29,000
total sulfur dioxide	115,745	118,000	111,000
desity	0,995	0,995	0,997
pH	3,219	3,210	3,160
sulphates	0,531	0,510	0,500
alcohol	10,492	10,300	9,500

Среднее арифметическое характеризует общий уровень значений признака. Медиана делит упорядоченный ряд наблюдений на две равные части, а мода показывает наиболее часто встречающееся значение.

Меры разброса

Для оценки изменчивости признаков были рассчитаны дисперсия, стандартное отклонение, межквартильный размах, медианное абсолютное отклонение, размах и коэффициент вариации.

```
variance = df[features].var(ddof=1)
std = df[features].std(ddof=1)
iqr = (df[features].quantile(0.75) - df[features].quantile(0.25))
mad = (df[features].sub(df[features].median()).abs().median())
data_range = df[features].max() - df[features].min()
cv = std / df[features].mean() * 100
```

```
dispersion = pd.DataFrame({
        'Дисперсия': variance,
        'Стандартное отклонение': std,
        'IQR': iqr,
        'MAD': mad,
        'Размах': data_range,
        'Коэффициент вариации, %': cv
})
display(dispersion.round(3))
```

Основная аналитическая таблица оформлена в соответствии с требованиями из методических указаний.

Таблица 9. Аналитические показатели количественных признаков

Переменная	Среднее	Дисперсия	Ст. откл.	IQR	MAD	Размах
fixed acidity	7,215	1,681	1,296	1,300	0,600	12,100
volatile acidity	0,340	0,027	0,165	0,170	0,080	1,500
citric acid	0,319	0,021	0,145	0,140	0,070	1,660
residual sugar	5,443	22,637	4,758	6,300	1,700	65,200
chlorides	0,056	0,001	0,035	0,027	0,011	0,602
free sulfur dioxide	30,525	315,041	17,749	24,000	12,000	288,000
total sulfur dioxide	115,745	3194,720	56,522	79,000	39,000	434,000
density	0,995	0,000	0,003	0,005	0,002	0,052
pH	3,219	0,026	0,161	0,210	0,110	1,290
sulphates	0,531	0,022	0,149	0,170	0,080	1,780
alcohol	10,492	1,423	1,193	1,800	0,900	6,900

Сравнение среднего и медианы

Для большинства признаков среднее значение и медиана различаются. Это указывает на асимметричность их распределений.

Интерпретация показателей разброса

Наибольший коэффициент вариации наблюдается у признаков `residual sugar`, `chlorides` и `total sulfur dioxide`. Это свидетельствует о наибольшей относительной изменчивости данных признаков. Для признака `density` коэффициент вариации наименьший. При этом показатели разброса рассчитаны для объединённой выборки. Поэтому их следует интерпретировать с учётом того, что датасет содержит два различных типа вина.

Вывод по части 3

В результате расчёта описательных статистик было установлено, что для большинства признаков среднее и медиана различаются, что указывает на асимметричную форму их распределений. Наибольшая относительная вариативность наблюдается у признаков, связанных с сахаром и хлоридами. Полученные результаты подтверждают необходимость дальнейшего сравнительного анализа распределений отдельно по типам вина.

Часть 4. Визуализация распределений

На данном этапе были исследованы распределения количественных признаков датасета Wine Quality с помощью гистограмм, Box Plot, эмпирической функции распределения и ядерной оценки плотности. Также были рассчитаны процентили и выполнена проверка потенциальных выбросов по правилу $1{,}5 \cdot IQR$.

Гистограммы с различным количеством бинов

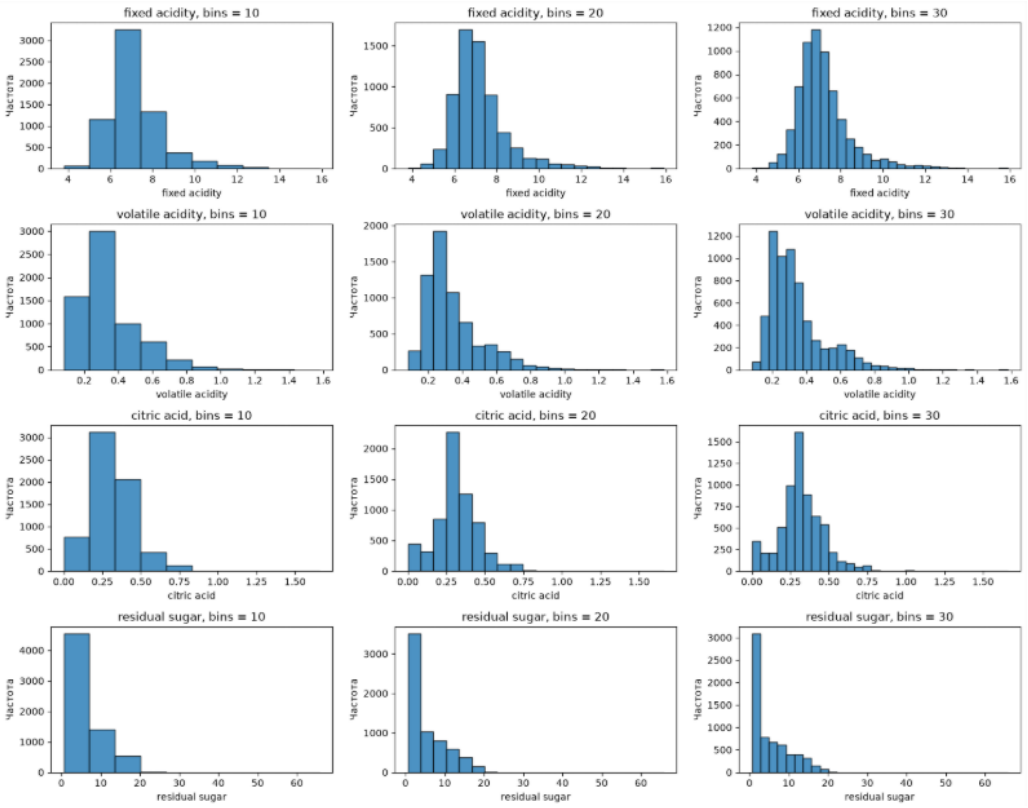
Для исследования влияния количества интервалов на форму гистограммы были использованы значения количества бинов, равные 10, 20 и 30.

```
bins_list = [10, 20, 30]

fig, axes = plt.subplots(len(features), len(bins_list), figsize=(15, 32))

for i, col in enumerate(features):
for j, b in enumerate(bins_list):
        ax = axes[i, j]
        ax.hist(df[col], bins=b, edgecolor='black', alpha=0.8)
        ax.set_title(f'{col}, bins = {b}')
        ax.set_xlabel(col)
        ax.set_ylabel('Частота')

plt.tight_layout()
plt.show()
```


fixed acidity, bins = 10
fixed acidity, bins = 20
fixed acidity, bins = 30
volatile acidity, bins = 10
volatile acidity, bins = 20
volatile acidity, bins = 30
citric acid, bins = 10
citric acid, bins = 20
citric acid, bins = 30
residual sugar, bins = 10
residual sugar, bins = 20
residual sugar, bins = 30
Частота
fixed acidity
volatile acidity
citric acid
residual sugar

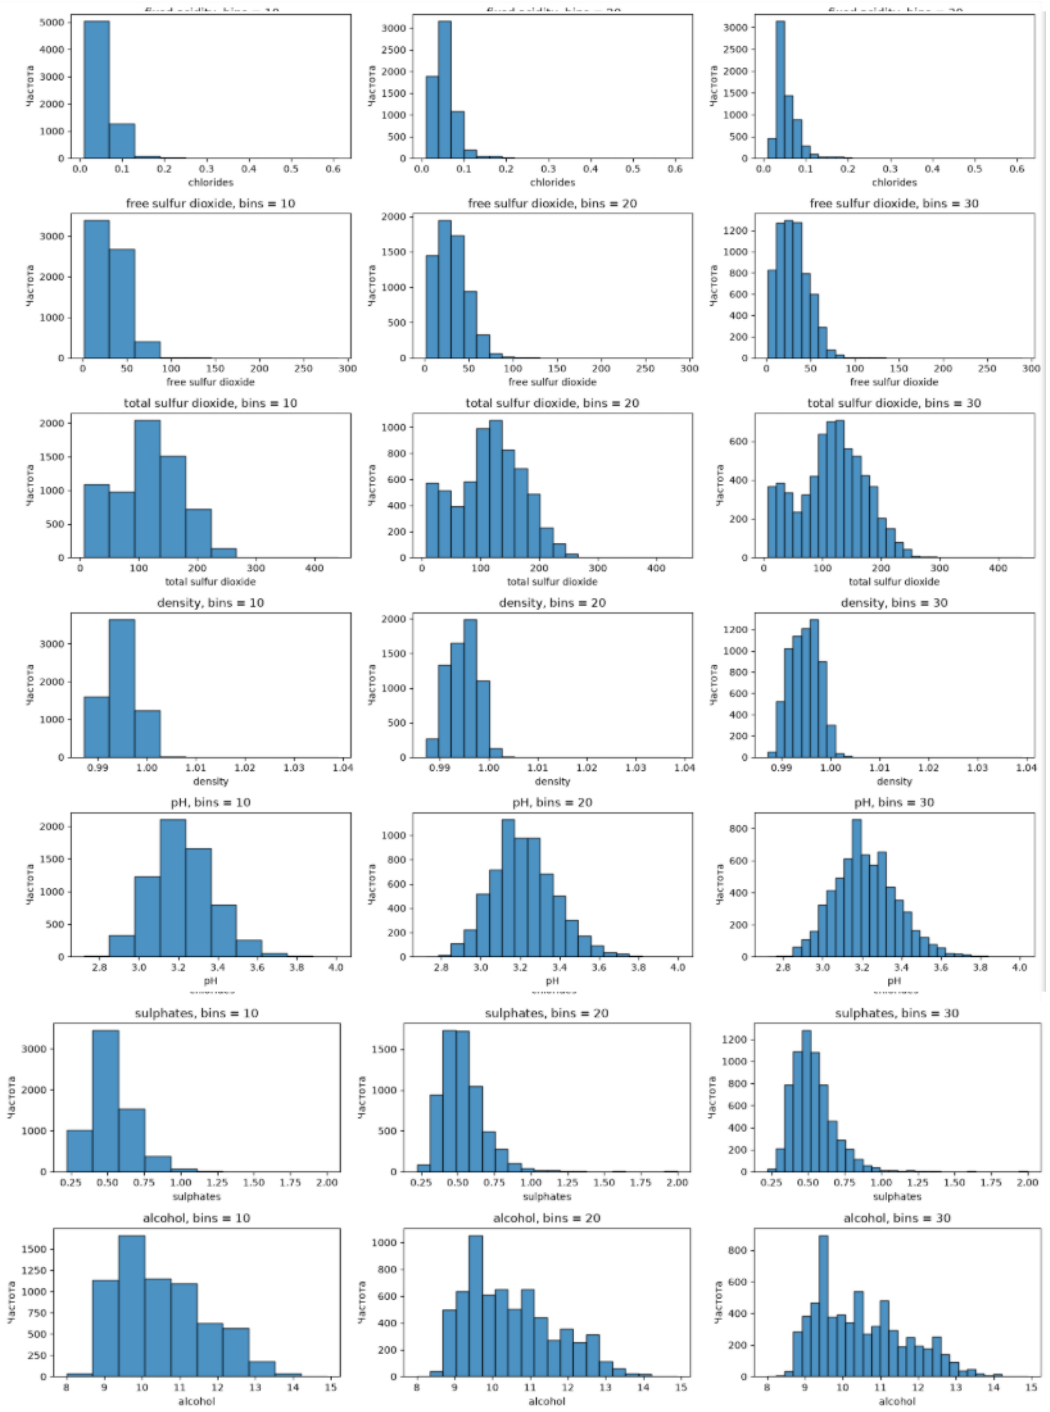


Рисунок 5 – Гистограммы количественных признаков при различном количестве бинов

При небольшом количестве бинов гистограмма получается более сглаженной, однако отдельные особенности распределения могут быть скрыты. При увеличении количества бинов становятся заметны дополнительные пики и промежутки между областями концентрации наблюдений.

Box Plot и обнаружение выбросов

Box Plot позволяет одновременно сравнить медиану, межквартильный размах и потенциальные выбросы количественных признаков.

```
fig, axes = plt.subplots(4, 3, figsize=(14, 14))
axes = axes.flatten()

for i, col in enumerate(features):
        ax = axes[i]
        sns.boxplot(y=df[col], ax=ax, color='steelblue')
        ax.set_title(f'Box Plot: {col}')
        ax.set_ylabel('Значение')
        ax.set_xlabel(col)
        ax.grid(axis='y', alpha=0.3)

# если признаков меньше, чем ячеек — убираем пустые
for j in range(len(features), len(axes)):
        fig.delaxes(axes[j])

plt.tight_layout()
plt.show()
```

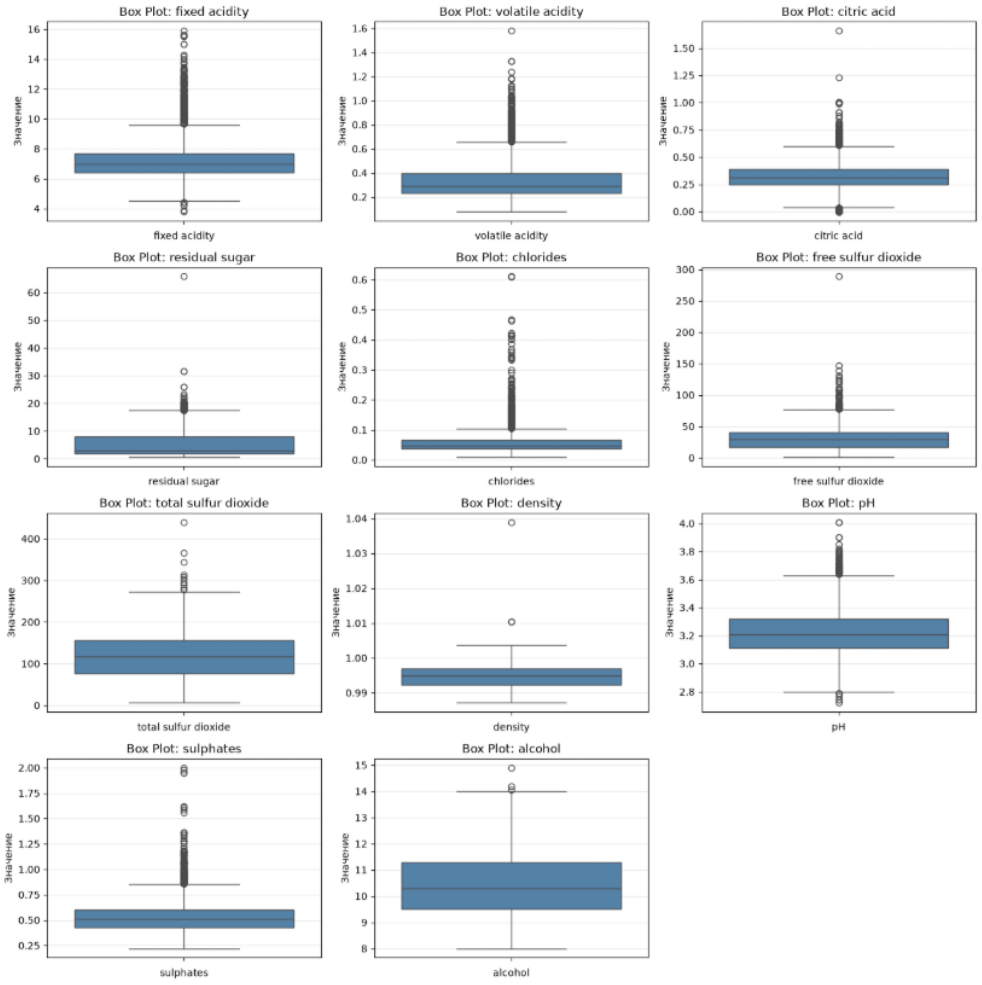


Рисунок 6 – Box Plot количественных признаков

Для обнаружения потенциальных выбросов использовалось правило $1{,}5 \cdot IQR$. Нижняя и верхняя границы определялись по формулам:

$$L = Q_1 - 1{,}5 \cdot IQR,$$

$$U = Q_3 + 1{,}5 \cdot IQR,$$

где Q_1 — нижний квартиль, Q_3 — верхний квартиль, а $IQR = Q_3 - Q_1$ — межквартильный размах.

```
Boutliers = {}
outliers = {}
for feature in features:
        q1 = df[feature].quantile(0.25)
        q3 = df[feature].quantile(0.75)
```

```
    iqr = q3 - q1
    lower_bound = q1 - 1.5 * iqr
    upper_bound = q3 + 1.5 * iqr
    mask = (df[feature] < lower_bound) | (df[feature] > upper_bound)
    outliers[feature] = df.loc[mask, feature]
    print(f'\nПризнак: {feature}')
    print(f'Q1 = {q1:.3f}')
    print(f'Q3 = {q3:.3f}')
    print(f'IQR = {iqr:.3f}')
    print(f'Нижняя граница = {lower_bound:.3f}')
    print(f'Верхняя граница = {upper_bound:.3f}')
    print(f'Количество выбросов: {mask.sum()}')
```

Таблица 10. Границы выбросов количественных признаков

Признак	Q_1	Q_3	IQR	Нижняя граница	Верхняя граница	Количество выбросов
fixed acidity	6,400	7,700	1,300	4,450	9,650	357
volatile acidity	0,230	0,400	0,170	−0,025	0,655	377
citric acid	0,250	0,390	0,140	0,040	0,600	509
residual sugar	1,800	8,100	6,300	−7,650	17,550	118
chlorides	0,038	0,065	0,027	−0,003	0,106	286
free sulfur dioxide	17,000	41,000	24,000	−19,000	77,000	62
total sulfur dioxide	77,000	156,000	79,000	−41,500	274,500	10
density	0,992	0,997	0,005	0,985	1,004	3
pH	3,110	3,320	0,210	2,795	3,635	73
sulphates	0,430	0,600	0,170	0,175	0,855	191
alcohol	9,500	11,300	1,800	6,800	14,000	3

Потенциальные выбросы были обнаружены у большинства признаков. Обнаруженные значения не следует автоматически удалять. Box Plot выделяет потенциальные выбросы только с точки зрения статистического правила, но они могут быть корректными наблюдениями для отдельных типов вина.

Эмпирическая функция распределения и процентили

Эмпирическая функция распределения, или CDF, позволяет определить долю наблюдений ниже заданного значения и сравнить распределения между собой.

```
fig, axes = plt.subplots(4, 3, figsize=(15, 14))
axes = axes.flatten()
for i, col in enumerate(features):
```

```
ax = axes[i]
sorted_data = np.sort(df[col])
yvals = np.arange(len(sorted_data)) / float(len(sorted_data) - 1)
        ax.step(sorted_data, yvals, where='post')
        ax.set_title(f'Эмпирическая CDF: {col}')
        ax.set_xlabel(col)
        ax.set_ylabel('F(x)')
        ax.grid(alpha=0.3)
plt.tight_layout()
plt.show()
```

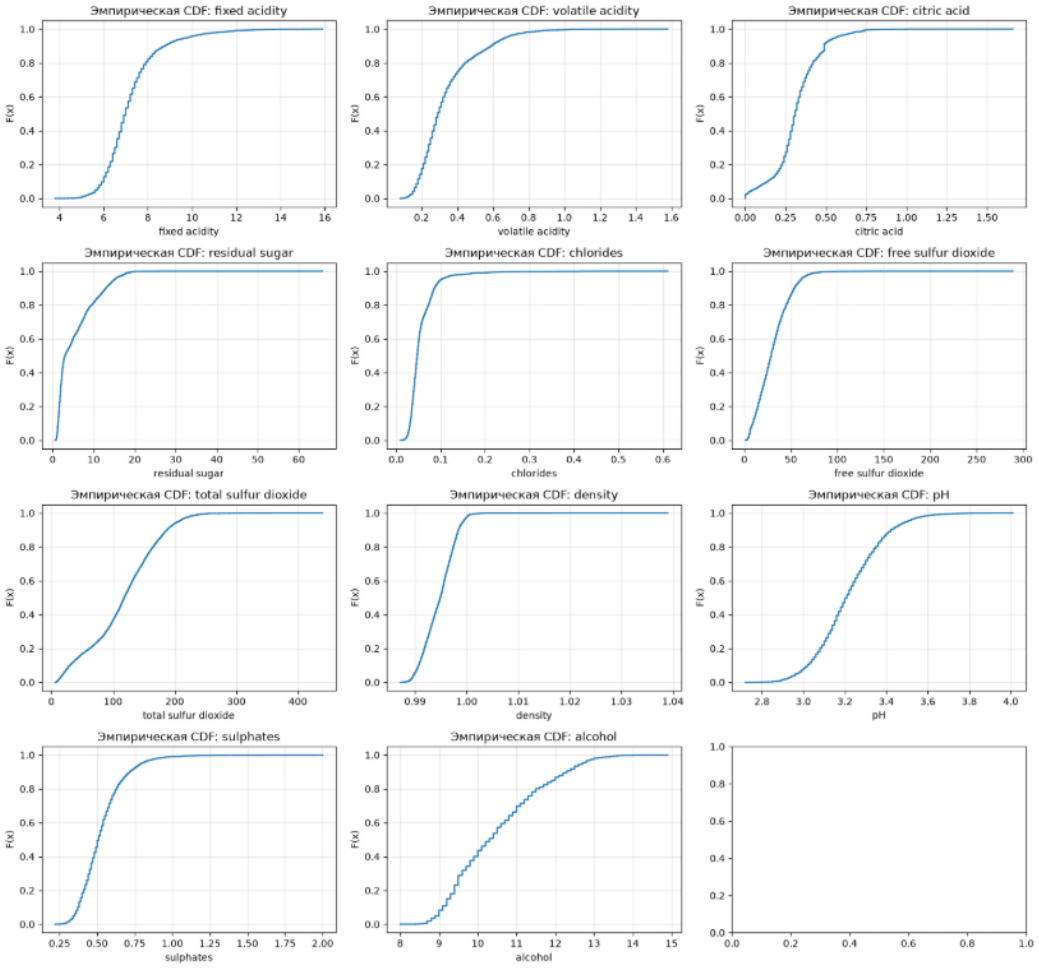


Рисунок 7 – Эмпирические функции распределения количественных признаков

```
percentiles = [10, 25, 50, 75, 90]
percentile_table = df[features].quantile(np.array(percentiles) /
↪  100)
percentile_table.index = [f'{p}-й процентиль' for p in percentiles]
display(percentile_table.round(3))
```

Таблица 11. Процентили количественных признаков

Процентиль	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol
10-й	6,0	0,18	0,14	1,3	0,031	9,0	30,0	0,991	3,02	0,37	9,1
25-й	6,4	0,23	0,25	1,8	0,038	17,0	77,0	0,992	3,11	0,43	9,5
50-й	7,0	0,29	0,31	3,0	0,047	29,0	118,0	0,995	3,21	0,51	10,3
75-й	7,7	0,40	0,39	8,1	0,065	41,0	156,0	0,997	3,32	0,60	11,3
90-й	8,8	0,59	0,49	13,0	0,086	54,0	188,0	0,998	3,42	0,72	12,3

KDE и сравнение с гистограммой

Для сглаженной оценки плотности распределений использовалась ядерная оценка плотности KDE..

```
fig, axes = plt.subplots(4, 3, figsize=(15, 14))
axes = axes.flatten()
for i, feature in enumerate(features):
        ax = axes[i]
        sns.histplot(data=df, x=feature, bins=20, stat='density', kde=True,
        ↪  ax=ax)
        ax.set_title(f'Гистограмма и KDE: {feature}')
        ax.set_xlabel(feature)
        ax.set_ylabel('Плотность')
plt.tight_layout()
plt.show()
```

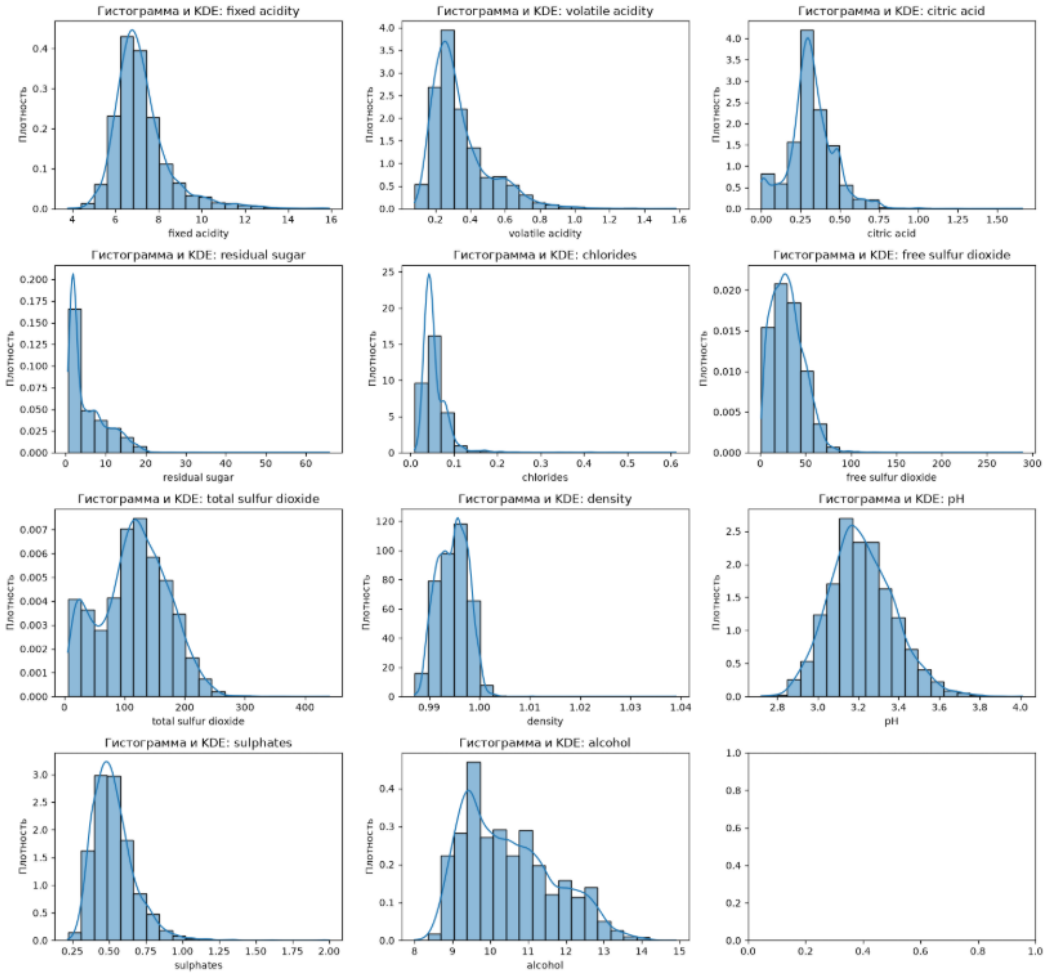


Рисунок 8 – Сравнение гистограмм и KDE

KDE подтверждает результаты, полученные с помощью гистограмм. Для многих признаков наблюдается несколько пиков, соответствующих различным группам вина.

Вывод по части 4

В результате визуального анализа было установлено, что изменение количества бинов влияет на детализацию гистограммы. Box Plot выявил потенциальные выбросы у большинства признаков. CDF и KDE показали существенные различия между распределениями. Следовательно, для более точной интерпретации распределения следует анализировать не только по общей выборке, но и отдельно по каждому типу вина.

Часть 5. Анализ взаимосвязей

На данном этапе были исследованы взаимосвязи между количественными признаками датасета Wine Quality. Для этого использовались диаграммы рассеяния, линии линейной регрессии, ковариация, коэффициент корреляции Пирсона, матрица диаграмм рассеяния, а также проверялось влияние потенциальных выбросов на корреляционные связи.

Диаграммы рассеяния с линией регрессии

Для анализа парных взаимосвязей между признаками были построены диаграммы рассеяния с линиями линейной регрессии.

```
pairs = [
        ('fixed acidity', 'volatile acidity'),
        ('fixed acidity', 'citric acid'),
        ('fixed acidity', 'residual sugar'),
        ('volatile acidity', 'citric acid'),
        ('alcohol', 'quality'),
        ('density', 'alcohol')
]

fig, axes = plt.subplots(2, 3, figsize=(17, 10))
for ax, (x, y) in zip(axes.flat, pairs):
        sns.regplot(data=df, x=x, y=y, ax=ax, scatter_kws={'alpha': 0.65},
        ↪  line_kws={'color': 'red'})
        ax.set_title(f'{x} и {y}')
plt.tight_layout()
plt.show()
```

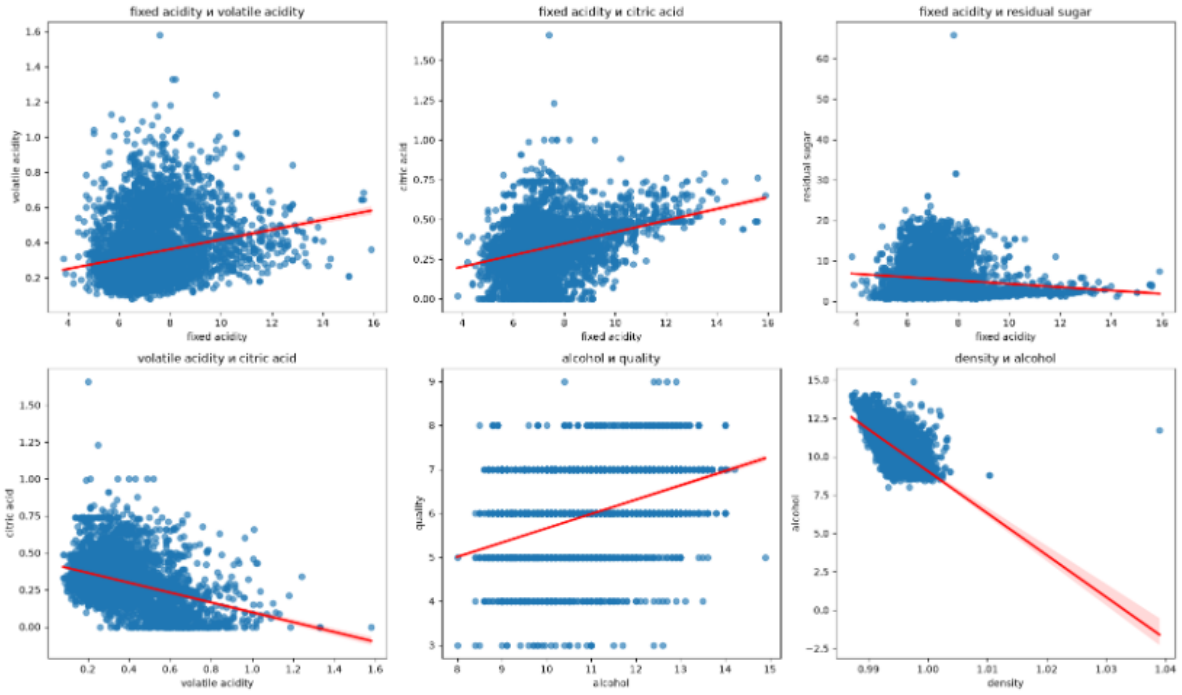


Рисунок 9 – Диаграммы рассеяния с линиями линейной регрессии

Ковариация

Ковариация характеризует направление совместного изменения двух признаков. Положительное значение ковариации указывает на увеличение одного признака при увеличении другого, а отрицательное значение — на противоположное направление изменения.

```
covariance_matrix = df[features].cov()
display(covariance_matrix.round(3))
```

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol
fixed acidity	1.681	0.047	0.061	-0.691	0.014	-6.506	-24.112	0.002	-0.053	0.058	-0.148
volatile acidity	0.047	0.027	-0.009	-0.154	0.002	-1.030	-3.857	0.000	0.007	0.006	-0.007
citric acid	0.061	-0.009	0.021	0.098	0.000	0.343	1.604	0.000	-0.008	0.001	-0.002
residual sugar	-0.691	-0.154	0.098	22.637	-0.021	34.022	133.245	0.008	-0.204	-0.132	-2.040
chlorides	0.014	0.002	0.000	-0.021	0.001	-0.121	-0.554	0.000	0.000	0.002	-0.011
free sulfur dioxide	-6.506	-1.030	0.343	34.022	-0.121	315.041	723.262	0.001	-0.416	-0.498	-3.807
total sulfur dioxide	-24.112	-3.857	1.604	133.245	-0.554	723.262	3194.720	0.005	-2.167	-2.319	-17.915
density	0.002	0.000	0.000	0.008	0.000	0.001	0.005	0.000	0.000	0.000	-0.002
pH	-0.053	0.007	-0.008	-0.204	0.000	-0.416	-2.167	0.000	0.026	0.005	0.023
sulphates	0.058	0.006	0.001	-0.132	0.002	-0.498	-2.319	0.000	0.005	0.022	-0.001
alcohol	-0.148	-0.007	-0.002	-2.040	-0.011	-3.807	-17.915	-0.002	0.023	-0.001	1.423

Рисунок 10 – Ковариационная матрица количественных признаков

Корреляция Пирсона

Коэффициент корреляции Пирсона показывает силу и направление линейной связи между двумя количественными признаками. Для расчёта корреляционной матрицы использовался следующий код:

```
pearson_matrix = df[features].corr(method='pearson')
display(pearson_matrix.round(3))

plt.figure(figsize=(10, 8))
sns.heatmap(pearson_matrix, annot=True, fmt='.2f', cmap='coolwarm', vmin=-1,
↪  vmax=1, square=True)
plt.title('Корреляция Пирсона')
plt.show()
```

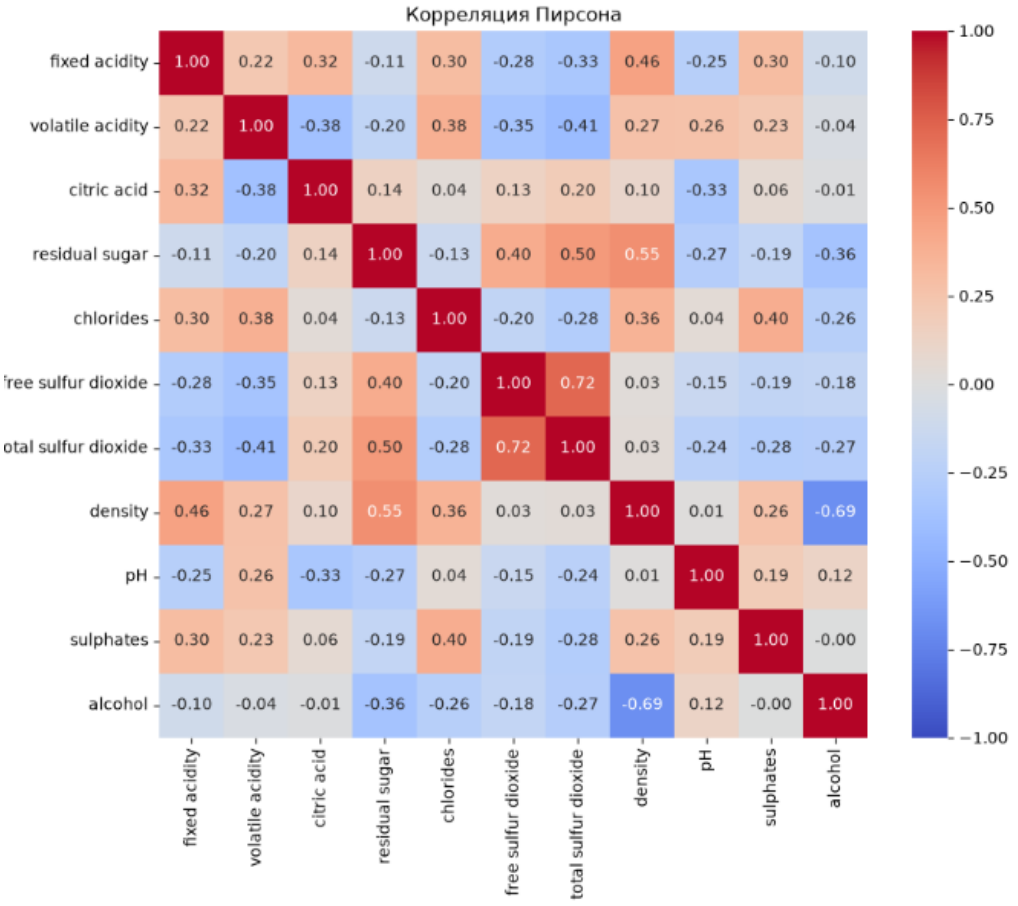


Рисунок 11 – Тепловая карта корреляций Пирсона

Матрица диаграмм рассеяния

Для одновременного анализа всех пар признаков была построена матрица диаграмм рассеяния с разделением наблюдений по типам вина.

```
sns.pairplot(df, vars=features, hue='type', diag_kind='hist')
plt.show()
```

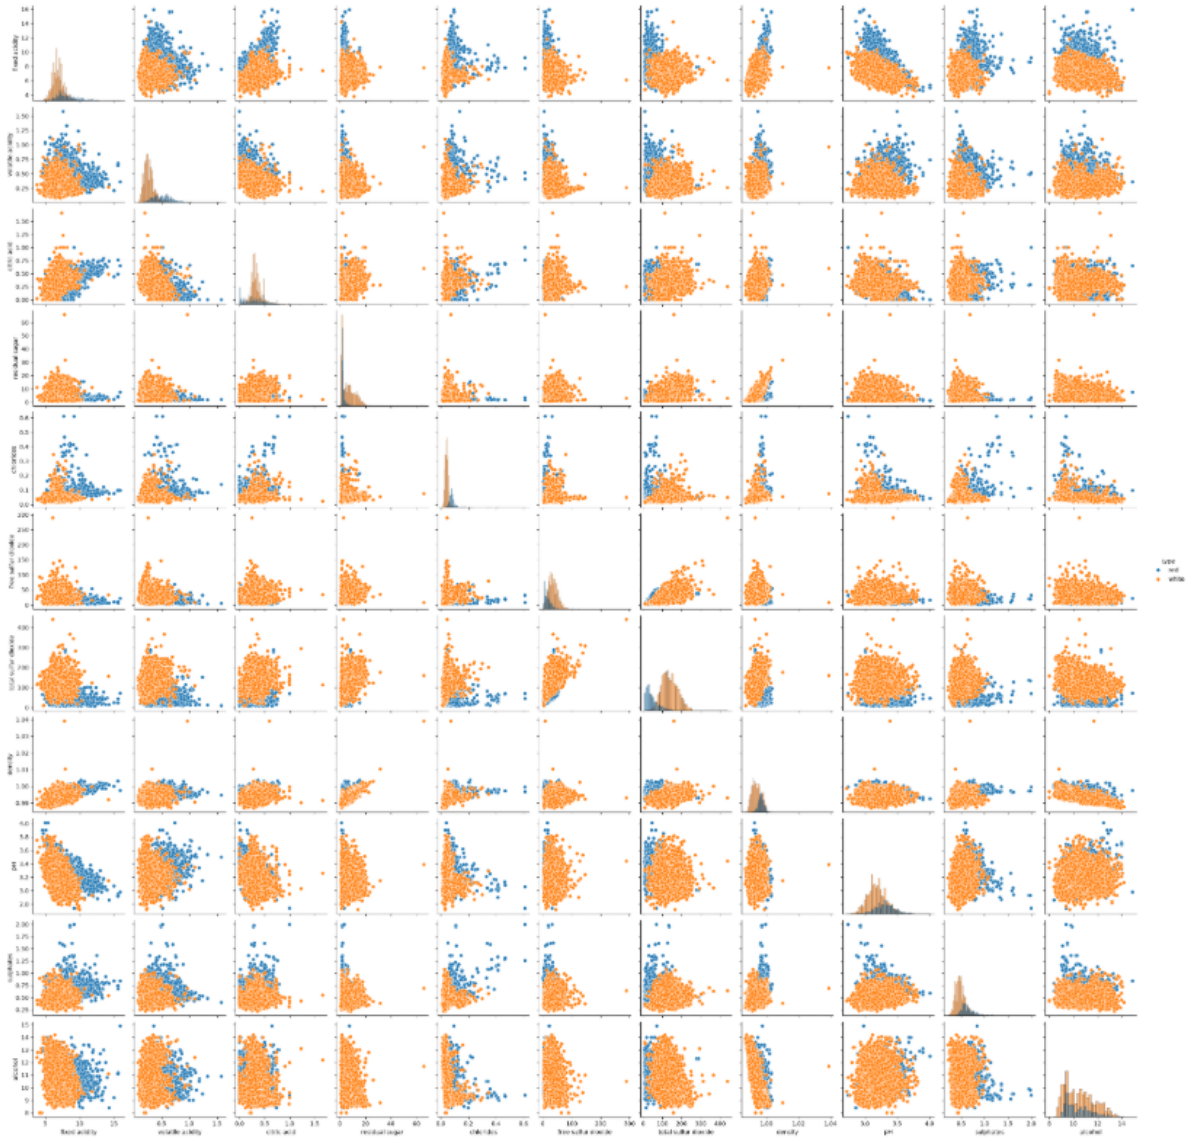


Рисунок 12 – Матрица диаграмм рассеяния количественных признаков

Проверка влияния потенциальных выбросов

В части 4 потенциальные выбросы были обнаружены у большинства признаков. Для проверки их влияния на корреляции были рассчитаны корреляционные матрицы до и после исключения таких наблюдений.

```
outlier_mask = pd.Series(False, index=df.index)
for feature in features:
q1 = df[feature].quantile(0.25)
```

```
q3 = df[feature].quantile(0.75)
iqr = q3 - q1
lower_bound = q1 - 1.5 * iqr
upper_bound = q3 + 1.5 * iqr
feature_outliers = (df[feature] < lower_bound) | (df[feature] > upper_bound)
outlier_mask = outlier_mask | feature_outliers

print('Количество наблюдений с потенциальными выбросами:',
↪  outlier_mask.sum())

corr_all = df[features].corr()
corr_without_outliers = df.loc[~outlier_mask, features].corr()

print('Корреляция для всей выборки:')
display(corr_all.round(3))
print('Корреляция без выбросов:')
display(corr_without_outliers.round(3))
```

```
Количество наблюдений с потенциальными выбросами: 1473
Корреляция для всей выборки:
```

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol
fixed acidity	1.000	0.219	0.324	-0.112	0.298	-0.283	-0.329	0.459	-0.253	0.300	-0.095
volatile acidity	0.219	1.000	-0.378	-0.196	0.377	-0.353	-0.414	0.271	0.261	0.226	-0.038
citric acid	0.324	-0.378	1.000	0.142	0.039	0.133	0.195	0.096	-0.330	0.056	-0.010
residual sugar	-0.112	-0.196	0.142	1.000	-0.129	0.403	0.495	0.553	-0.267	-0.186	-0.359
chlorides	0.298	0.377	0.039	-0.129	1.000	-0.195	-0.280	0.363	0.045	0.396	-0.257
free sulfur dioxide	-0.283	-0.353	0.133	0.403	-0.195	1.000	0.721	0.026	-0.146	-0.188	-0.180
total sulfur dioxide	-0.329	-0.414	0.195	0.495	-0.280	0.721	1.000	0.032	-0.238	-0.276	-0.266
density	0.459	0.271	0.096	0.553	0.363	0.026	0.032	1.000	0.012	0.259	-0.687
pH	-0.253	0.261	-0.330	-0.267	0.045	-0.146	-0.238	0.012	1.000	0.192	0.121
sulphates	0.300	0.226	0.056	-0.186	0.396	-0.188	-0.276	0.259	0.192	1.000	-0.003
alcohol	-0.095	-0.038	-0.010	-0.359	-0.257	-0.180	-0.266	-0.687	0.121	-0.003	1.000

```
Корреляция без выбросов:
```

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol
fixed acidity	1.000	0.151	0.238	-0.033	0.318	-0.173	-0.152	0.347	-0.250	0.134	-0.113
volatile acidity	0.151	1.000	-0.321	-0.115	0.428	-0.282	-0.265	0.185	0.182	0.173	-0.010
citric acid	0.238	-0.321	1.000	0.096	-0.118	0.139	0.170	0.031	-0.176	0.021	0.042
residual sugar	-0.033	-0.115	0.096	1.000	-0.049	0.417	0.475	0.652	-0.245	-0.127	-0.396
chlorides	0.318	0.428	-0.118	-0.049	1.000	-0.188	-0.235	0.524	0.204	0.308	-0.395
free sulfur dioxide	-0.173	-0.282	0.139	0.417	-0.188	1.000	0.680	0.169	-0.125	-0.100	-0.202
total sulfur dioxide	-0.152	-0.265	0.170	0.475	-0.235	0.680	1.000	0.231	-0.192	-0.160	-0.328
density	0.347	0.185	0.031	0.652	0.524	0.169	0.231	1.000	0.054	0.200	-0.776
pH	-0.250	0.182	-0.176	-0.245	0.204	-0.125	-0.192	0.054	1.000	0.278	0.057
sulphates	0.134	0.173	0.021	-0.127	0.308	-0.100	-0.160	0.200	0.278	1.000	-0.033
alcohol	-0.113	-0.010	0.042	-0.396	-0.395	-0.202	-0.328	-0.776	0.057	-0.033	1.000

Рисунок 13 – Корреляция для всей выборки и без выбросов

Вывод по части 5

В результате анализа взаимосвязей было установлено, что наиболее сильная положительная корреляция наблюдается между `free sulfur dioxide` и `total sulfur dioxide`. Также наблюдается положительная связь между `alcohol` и `quality`. Матрица диаграмм рассеяния показала, что признаки `alcohol` и `volatile acidity` лучше всего разделяют типы вина. Проверка влияния потенциальных выбросов показала, что их исключение незначительно изменяет значения коэффициентов корреляции.

Часть 6. Сравнительный анализ

На данном этапе был проведён сравнительный анализ распределений количественного признака по группам, заданным категориальной переменной.

Выбор категориальной и количественной переменных

В качестве категориальной переменной был выбран признак `type`, содержащий названия двух типов вина: `red` и `white`. В качестве количественной переменной был выбран признак `alcohol`, характеризующий содержание алкоголя в процентах.

Box Plot по группам

Для сравнения распределений содержания алкоголя между типами вина были построены Box Plot по группам.

```
plt.figure(figsize=(10, 6))
sns.boxplot(data=df, x='type', y='alcohol')
plt.title('Сравнение содержания алкоголя по типам вина')
plt.xlabel('Тип вина')
plt.ylabel('Содержание алкоголя')
plt.grid(axis='y', alpha=0.3)
plt.show()
```

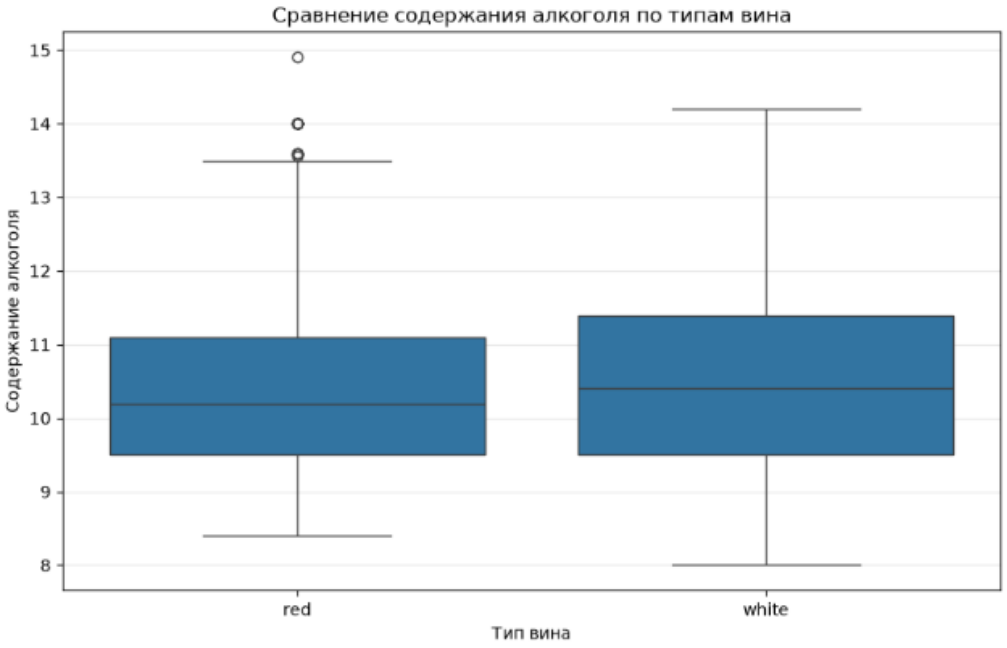


Рисунок 14 – Сравнение содержания алкоголя по типам вина

Эмпирическая функция распределения по группам

Для дополнительного сравнения групп были построены эмпирические функции распределения CDF.

```
plt.figure(figsize=(10, 6))
for wine_type in df['type'].unique():
        values = np.sort(df.loc[df['type'] == wine_type, 'alcohol'])
        probabilities = np.arange(1, len(values) + 1) / len(values)
        plt.step(values, probabilities, where='post', label=wine_type)
plt.title('CDF для содержания алкоголя по типам вина')
plt.xlabel('Содержание алкоголя')
plt.ylabel('F(x)')
plt.ylim(0, 1.05)
plt.grid(alpha=0.3)
plt.legend()
plt.show()
```

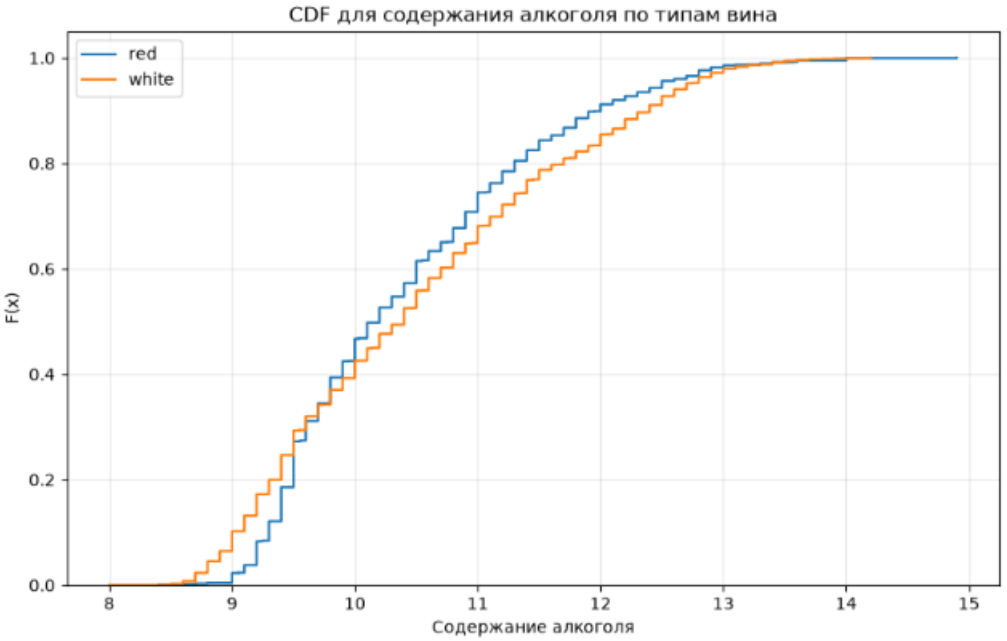


Рисунок 15 – CDF для содержания алкоголя по типам вина

Сравнение медиан и разброса

Для количественного сравнения групп были рассчитаны среднее значение, медиана, стандартное отклонение, минимальное и максимальное значения, первый и третий квартили, а также межквартильный размах.

```
group_statistics = df.groupby('type')['alcohol'].agg(
        Среднее='mean',
        Медиана='median',
        Стандартное_отклонение='std',
        Минимум='min',
        Максимум='max',
        Q1=lambda x: x.quantile(0.25),
        Q3=lambda x: x.quantile(0.75)
)
group_statistics['IQR'] = group_statistics['Q3'] - group_statistics['Q1']
display(group_statistics.round(3))
```

Таблица 12. Сравнительные статистики по типу вина

type	Среднее	Медиана	Стандартное отклонение	Минимум	Максимум	Q1	Q3	IQR
red	10,423	10,2	1,066	8,4	14,9	9,5	11,1	1,6
white	10,514	10,4	1,231	8,0	14,2	9,5	11,4	1,9

Интерпретация различий между группами

Результаты Box Plot, CDF и численного сравнения показывают, что типы вина имеют существенно различающиеся распределения признака alcohol. Белое вино характеризуется несколько более высоким средним и медианным содержанием алкоголя, а также большим разбросом значений. Красное вино имеет более низкие и более сгруппированные значения.

Вывод по части 6

В качестве категориальной переменной был выбран признак `type`, а в качестве количественной переменной — `alcohol`. Сравнительный анализ показал, что медианные значения содержания алкоголя существенно различаются между типами вина. Следовательно, признак `alcohol` позволяет хорошо различать типы вина и может рассматриваться как информативный признак для дальнейшего моделирования или классификации.

Выводы и практические рекомендации

Описание данных и их типов

В работе был исследован датасет Wine Quality, загруженный из файла wine_quality_merged.csv. Датасет содержит 6497 наблюдений и 13 признаков. Одиннадцать признаков являются количественными непрерывными признаками, измеренными по шкале отношений. Признак quality является категориальным порядковым признаком. Признак type является категориальным номинальным признаком.

Результаты проверки базовых предположений

Проверка с помощью 4-Plot показала, что исходный порядок наблюдений не является случайным. Это связано с тем, что в датасете сначала расположены объекты одного типа вина, а затем другого. Гистограммы и Normal Probability Plot показали, что признаки имеют многомодальные распределения в общей выборке. Для большинства признаков соответствие нормальному распределению является только приблизительным, также имеются отклонения в хвостах.

Описательные статистики и их интерпретация

Для количественных признаков были рассчитаны меры центральной тенденции и меры разброса. Среднее и медиана большинства признаков имеют различные значения. Это указывает на асимметричность их распределений. Наибольший коэффициент вариации наблюдается у признаков residual sugar, chlorides и total sulfur dioxide. Для признака density коэффициент вариации наименьший.

Визуализации и основные результаты

В работе были построены следующие визуализации: гистограммы, Box Plot, эмпирические функции распределения, графики KDE, диаграммы рассеяния, тепловая карта корреляций, матрица диаграмм рассеяния, Box Plot и CDF по типам вина. Гистограммы и KDE подтвердили наличие нескольких областей концентрации значений для большинства признаков. Матрица диаграмм рассеяния показала, что признаки alcohol и volatile acidity лучше всего разделяют типы вина.

Аномалии, выбросы и пропуски

В датасете отсутствуют пропущенные значения. Также было обнаружено 1169 полных дублирующихся наблюдений.

По правилу $1{,}5 \cdot IQR$ потенциальные выбросы были обнаружены у большинства признаков. Данные наблюдения не удалялись автоматически, поскольку статистическое правило выделяет только потенциальные выбросы. Они могут быть корректными измерениями для отдельных типов вина. После исключения потенциальных выбросов значения корреляций изменились незначительно.

Гипотезы для дальнейшего анализа

По результатам исследования были сформулированы следующие гипотезы:

1. Между `free sulfur dioxide` и `total sulfur dioxide` существует сильная положительная связь.
2. Признак `alcohol` позволяет хорошо различать типы вина.
3. Признаки `volatile acidity` и `citric acid` также могут быть информативны для различения типов вина.
4. Потенциальные выбросы в признаках не оказывают существенного влияния на корреляции между признаками.
5. Признаки `alcohol` и `volatile acidity` являются наиболее информативными для классификации типов вина.

Общий вывод о применимости моделей

Исследуемый датасет пригоден для дальнейшего применения методов статистического анализа и классификации. В нём отсутствуют пропуски, группы имеют различный размер, а признаки `alcohol` и `volatile acidity` позволяют хорошо различать типы вина.

При построении моделей необходимо учитывать несколько особенностей данных. Во-первых, наблюдения в исходном датасете упорядочены по типу вина, поэтому для обучения моделей выборку следует перемешивать и разделять на обучающую и тестовую части с сохранением пропорций групп. Во-вторых, общие распределения признаков являются многомодальными.

Поэтому их желательно анализировать отдельно по типам или использовать методы, не требующие строгого предположения о нормальности распределения. В-третьих, для методов, основанных на расстояниях или коэффициентах регрессии, может потребоваться стандартизация количественных признаков. Потенциальные выбросы следует проверять с учётом предметного смысла, а не удалять автоматически.